

面向具身智能关节状态预测的轻量级状态空间世界模型

周新民^{1,2}, 余焕杰^{3†}, 张慧慧⁴, 王伟³, 陈露⁴

(1. 湖南工商大学 人工智能与机器人学院, 湖南 长沙 410205;

2. 湘江实验室, 湖南 长沙 410205;

3. 湖南工商大学 人工智能与机器人学院, 湖南 长沙 410205;

4. 湖南工商大学 前沿交叉学院, 湖南 长沙 410205)

摘要: 本文提出了一种基于对角状态空间模型的轻量级世界模型 S4D-WM, 用于机器人关节状态预测. 在 D4RL Humanoid 数据集上, S4D-WM 的预测精度最优, MSE 为 0.245, 优于 LSTM-WM 约 33%, 优于 Transformer-WM 约 12%, 优于 Mamba-WM 约 5%. S4D-WM 的参数量仅为 0.23M, 为所有对比方法中最少, 推理时间 8.3ms 满足实时控制要求. 在 D4RL Ant 数据集上, S4D-WM 与 Transformer-WM 性能接近, 差距仅 1.4%. 序列长度敏感性分析揭示了最优序列长度与数据集维度的相关性: 高维 Humanoid 适合短序列, 低维 Ant 适合长序列. 门控阈值函数对比实验表明, 软阈值门控优于硬阈值 13.7% 和 Garrote 阈值 24.6%. 模型预测控制实验表明, S4D-WM-MPC 的回路时间与 Mamba-MPC 相近, 两者均受限于 SSM 类模型反向传播的计算开销, LSTM-MPC 因 cuDNN 优化而具有速度优势.

关键词: 状态空间模型; 世界模型; 关节状态预测; 模型预测控制; 具身智能

引用格式: 周新民, 余焕杰, 张慧慧, 等. 面向具身智能关节状态预测的轻量级状态空间世界模型. 控制理论与应用, xxxx, xx(x): xxx – xxx

DOI: 10.7641/CTA.202x.xxxxx

代码开源: <https://github.com/SEMHAQ/SSM-World-Model>

Lightweight State Space World Model for Joint State Prediction in Embodied Intelligence

ZHOU Xin-min^{1,2}, YU Huan-jie^{3†}, ZHANG Hui-hui⁴, WANG Wei³, CHEN Lu⁴

(1. School of Artificial Intelligence and Robotics, Hunan University of Technology and Business, Changsha Hunan 410205, China;

2. Xiangjiang Laboratory, Changsha Hunan 410205, China;

3. School of Artificial Intelligence and Robotics, Hunan University of Technology and Business, Changsha Hunan 410205, China;

4. School of Frontier Crossover Studies, Hunan University of Technology and Business, Changsha Hunan 410205, China)

Abstract: This paper proposes S4D-WM, a lightweight world model based on diagonal state space models for robot joint state prediction. On the D4RL Humanoid dataset, S4D-WM achieves the best prediction accuracy with MSE of 0.245, outperforming LSTM-WM by 33%, Transformer-WM by 12%, and Mamba-WM by 5%. With only 0.23M parameters, S4D-WM has the smallest model size among all compared methods, and its 8.3ms inference time meets real-time control requirements. On the D4RL Ant dataset, S4D-WM performs comparably to Transformer-WM with only 1.4% gap. Sequence length sensitivity analysis reveals that optimal sequence length depends on dataset dimensionality. A gating threshold function comparison shows that soft-threshold gating outperforms hard thresholding by 13.7% and Garrote thresholding by 24.6%. Model predictive control experiments show that S4D-WM-MPC has similar loop time to Mamba-MPC, both limited by backward pass computation of SSM models, while LSTM-MPC benefits from cuDNN optimization for faster control.

Key words: state space model; world model; joint state prediction; model predictive control; embodied intelligence

Citation: X. Zhou, H. Yu, H. Zhang, et al. Lightweight state space world model for joint state prediction in embodied intelligence. *Control Theory & Applications*, xxxx, xx(x): xxx – xxx

收稿日期: xxxx-xx-xx; 录用日期: xxxx-xx-xx.

† 通讯作者. E-mail: semhaqx@gmail.com.

本文责任编辑: XXX.

国家自然科学基金项目 (21BGL231), 湘江实验室重大项目 (24XJ01001; 25XJ01001) 资助.

Supported by the National Social Science Fund of China (21BGL231) and the Major Program of Xiangjiang Laboratory (24XJ01001; 25XJ01001).

1 引言

具身智能的核心在于智能体通过与物理环境的实时交互来学习、进化并执行任务^[1]。机器人作为具身智能的重要载体,其高维度、强非线性及欠驱动特性使得“感知-决策-控制”的闭环实现极具挑战。其中,世界模型作为环境的内部表征,能够预测系统在给定动作下的未来状态,是实现模型预测控制(model predictive control, MPC)和规划决策的关键组件^[2]。

近年来,基于深度学习的世界模型取得了显著进展。基于循环神经网络 RNN 的方法^[3]虽然能够建模时序依赖,但存在梯度消失和长程依赖捕捉困难的问题。基于 Transformer 的方法^[4]通过自注意力机制有效解决了长程依赖问题,但其二次计算复杂度 $O(T^2)$ 在长序列场景下带来显著的计算开销。在具身智能领域,RT-2^[5]等大规模视觉-语言-动作模型展示了世界模型在机器人控制中的巨大潜力,但其庞大的参数量和计算需求使得部署在资源受限的机器人平台上面临严峻挑战。

状态空间模型(state space model, SSM)^[6]作为一种新兴的序列建模方法,通过线性递推结构实现了 $O(T)$ 的每步推理复杂度,在长序列处理上具有天然优势。S4^[6]通过结构化参数化解决了 SSM 的长程依赖问题,在 Long Range Arena 基准上取得了突破性结果。S4D^[7]进一步简化了对角 SSM 的参数化方案,在保持性能的同时降低了实现复杂度。Mamba^[8]引入选择性扫描机制,使 SSM 能够根据输入内容动态调整状态更新策略,在语言建模任务上首次超越了同等规模的 Transformer 模型。Mamba-2^[9]进一步揭示了 SSM 与注意力机制之间的对偶关系,为统一理解序列建模方法提供了新的理论视角。

然而,将 SSM 应用于具身智能领域的世界模型构建尚处于起步阶段。现有工作主要集中在视觉感知和语言理解领域,而在机器人状态预测和控制方面的探索相对有限。近期,Mamba 策略网络和 SSM 轨迹预测等工作开始将 SSM 引入机器人领域,但前者侧重于策略学习,后者侧重于行人轨迹预测,均未涉及面向具身智能关节状态预测的世界模型构建及其与 MPC 的集成。具身智能关节状态预测任务面临三重挑战:状态维度高,涉及多个关节的耦合动力学;动作-状态映射具有强非线性;且控制回路要求毫秒级的推理延迟。这些特点要求世界模型在保持高预测精度的同时,具备极低的计算开销。

本文的主要贡献如下:

1) 系统研究了基于 SSM 的世界模型在机器人状态预测中的应用,结合 S4D 风格的对角 SSM 参

数化与 Mamba 风格的门控块结构,构建了轻量级世界模型(S4D-WM)。与现有 SSM 在语言建模和长序列基准上的应用不同,本文将 SSM 引入具身智能控制领域,利用快速傅里叶变换 FFT 卷积实现 $O(T \log T)$ 的训练计算复杂度和 $O(1)$ 的单步推理复杂度,无需自定义 CUDA 算子即可部署;

2) 在 D4RL 基准数据集上进行了系统的实验验证。在 Humanoid 数据集上, S4D-WM 的预测精度最优 (MSE=0.245), 优于 LSTM-WM 提升 33%、Transformer-WM 提升 12%, Mamba-WM 提升 5%, 参数量仅为 0.23M, 为所有方法中最少; 在 Ant 数据集上, S4D-WM 与 Transformer-WM 性能接近, 差距仅 1.4%, 且参数效率最优;

3) 通过序列长度敏感性分析揭示了最优序列长度与数据集维度的相关性: Humanoid 在 $T=16$ 时最优, Ant 在 $T=128$ 时最优, 为实际部署提供了重要指导。消融实验验证了各组件的贡献, 门控阈值函数对比表明软阈值显著优于其他方案。

本文其余部分组织如下: 第 2 节回顾相关工作; 第 3 节介绍问题描述与预备知识; 第 4 节详述所提方法; 第 5 节给出实验结果与分析; 第 6 节总结全文并展望未来工作。

2 相关工作

2.1 机器人世界模型

世界模型的概念最早可追溯到 Karl Friston 的主动推理理论, 其核心思想是智能体通过构建环境的内部模型来进行预测和规划。在深度学习时代, Ha 和 Schmidhuber^[2]提出了基于变分自编码器 VAE 和循环神经网络的世界模型框架, 通过学习压缩的环境表征来实现策略学习。Hafner 等人^[10]提出了 Dreamer 系列方法, 利用潜在动力学模型在想象中进行策略优化, 在多个连续控制基准上取得了领先性能。DreamerV3^[11]进一步统一了离散和连续动作空间的处理, 展示了世界模型的通用性。

在机器人领域, Michels 等人探索了利用世界模型进行视觉伺服控制。Nagabandi 等人^[12-14]将神经网络动力学模型与模型预测控制相结合, 实现了机器人腿部运动的快速适应。近期, RT-2^[5]将大规模视觉-语言模型与机器人动作空间对齐, 展示了基础模型在机器人控制中的潜力。然而, 这些方法普遍面临计算开销大、难以满足实时控制要求的问题。在高效计算方面, TinyML^[15]和模型压缩技术为资源受限平台上的深度学习部署提供了解决方案。在仿真到真实迁移方面, 域随机化和快速电机适应 RMA 等方法缩小了仿真与真实机器人之间的差距。世界模型在自动驾驶领域也得到了广泛关注^[16], 连

续-离散状态空间模型为混合系统建模提供了新思路. 本文提出的 S4D-WM 旨在以极低的计算开销实现高质量的状态预测, 填补轻量级世界模型在机器人领域的空白.

2.2 状态空间模型

状态空间模型 (SSM) 源于控制理论中的线性系统描述^[6], 近年来在深度学习领域引起了广泛关注. Gu 等人^[17]提出的 HiPPO 框架通过最优多项式投影解决了连续时间记忆问题, 为 SSM 在序列建模中的应用奠定了理论基础. S4^[6]通过结构化参数化解决了 SSM 在长程依赖建模中的数值稳定性问题, 在 Long Range Arena 基准上取得了突破性结果.

在 S4 的基础上, 研究者提出了多种改进方案. S4D^[7]简化了对角 SSM 的参数化, 直接使用复数对角矩阵, 在保持性能的同时显著降低了实现复杂度. S5^[18]引入 MIMO-SSM 结构, 通过并行扫描算法实现了更高效的训练. H3^[19]结合了 SSM 与门控注意力, 在语言建模中取得了与 Transformer 相当的性能.

Mamba^[8]是 SSM 发展的一个重要里程碑. 它引入了选择性扫描机制, 使 SSM 的状态更新能够根据输入内容动态调整, 从而在保持线性计算复杂度的同时实现了与 Transformer 相当的建模能力. Mamba 的块结构已成为现代 SSM 架构的标准设计模式. Mamba-2^[9]进一步揭示了 SSM 与注意力机制之间的结构化状态空间对偶性, 为统一理解不同序列建模方法提供了新的理论框架. 本文基于 S4D 风格的对角 SSM 构建世界模型, 并采用 Mamba 风格的门控块结构, 在世界模型任务中验证了这一架构组合的有效性.

近期, SSM 类方法也开始在机器人领域得到应用. 在策略学习方面, Mamba 被用于替代 Transformer 作为策略网络的主干, 实现了更高效的序列决策. 在轨迹预测方面, SSM 被用于预测行人的未来轨迹, 利用其长程建模能力捕捉行人的运动模式. 在世界模型方面, Dreamer^[10]等方法使用循环神经网络或潜在动力学模型进行环境建模, 但这些方法主要面向视觉输入, 且计算开销较大. 本文聚焦于状态-动作序列的世界模型构建, 填补了轻量级 SSM 在机器人状态预测领域的空白.

2.3 轻量级模型与实时控制

在资源受限的机器人平台上部署深度学习模型是一个重要挑战. 知识蒸馏、模型剪枝和量化^[6]是常用的模型压缩方法. 网络架构搜索 NAS 也被用于自动设计高效的网络结构. 然而, 这些方法通常是事后压缩, 可能导致性能损失.

从架构设计角度出发, 门控循环单元 GRU 通过

简化 LSTM 的门控结构减少了参数量. 时间卷积网络 TCN 利用因果卷积和膨胀卷积实现了高效的序列建模. SSM 类方法^[6,8]通过线性递推结构实现了 $O(T)$ 的每步推理复杂度和 $O(1)$ 的单步延迟, 在长序列场景下具有显著的计算优势. 本文的 S4D-WM 直接从轻量级架构设计出发, 无需额外的压缩步骤即可满足实时控制要求.

2.4 模型预测控制与学习模型

模型预测控制 (MPC) 是一种基于模型的优化控制方法, 通过在每个控制时刻求解有限时域优化问题来确定最优动作^[12]. MPC 的核心在于动力学模型的准确性: 模型越精确, 控制性能越好. 传统的 MPC 使用解析模型 (如刚体动力学), 但在复杂环境中获取精确的解析模型往往困难重重.

将学习模型与 MPC 结合是一个活跃的研究方向. Nagabandi 等人^[12]展示了神经网络动力学模型在 MPC 中的有效性. Chua 等人^[20]提出了 PETS 方法, 通过概率集成模型处理模型不确定性. Hafner 等人^[10]的 Dreamer 方法则将潜在动力学模型与 MPC 相结合. 本文将 S4D-WM 嵌入 MPC 框架, 利用其快速推理能力实现高频控制回路^[21].

3 问题描述与预备知识

3.1 世界模型问题描述

设机器人在时刻 t 的状态为 $\mathbf{s}_t \in \mathbb{R}^{d_s}$, 执行的动作 $\mathbf{a}_t \in \mathbb{R}^{d_a}$. 状态向量包含各关节的角度、角速度等信息, 动作向量对应各关节的力矩或目标位置. 世界模型的目标是学习状态转移函数:

$$\mathbf{s}_{t+1} = f(\mathbf{s}_t, \mathbf{a}_t), \quad (1)$$

使得给定历史观测序列 $\{\mathbf{s}_{0:T}, \mathbf{a}_{0:T-1}\}$, 能够预测未来 H 步的状态轨迹 $\hat{\mathbf{s}}_{T+1:T+H}$. 在实际应用中, 状态转移函数 f 通常具有高维、非线性和耦合的特性.

3.2 状态空间模型

连续时间状态空间模型定义为:

$$\dot{\mathbf{h}}(t) = \mathbf{A}\mathbf{h}(t) + \mathbf{B}\mathbf{x}(t), \quad (2)$$

$$\mathbf{y}(t) = \mathbf{C}\mathbf{h}(t) + \mathbf{D}\mathbf{x}(t), \quad (3)$$

其中 $\mathbf{h}(t) \in \mathbb{R}^N$ 为隐状态, $\mathbf{x}(t)$ 为输入, $\mathbf{y}(t)$ 为输出, $\mathbf{A} \in \mathbb{R}^{N \times N}$, $\mathbf{B} \in \mathbb{R}^{N \times 1}$, $\mathbf{C} \in \mathbb{R}^{1 \times N}$, $\mathbf{D} \in \mathbb{R}$ 为系统参数.

经零阶保持零阶保持离散化后, SSM 可表示为:

$$\mathbf{h}_k = \bar{\mathbf{A}}\mathbf{h}_{k-1} + \bar{\mathbf{B}}\mathbf{x}_k, \quad (4)$$

$$\mathbf{y}_k = \mathbf{C}\mathbf{h}_k + \mathbf{D}\mathbf{x}_k, \quad (5)$$

其中 $\bar{\mathbf{A}} = \exp(\Delta\mathbf{A})$, $\bar{\mathbf{B}} = (\Delta\mathbf{A})^{-1}(\exp(\Delta\mathbf{A}) - \mathbf{I}) \cdot \Delta\mathbf{B}$, Δ 为采样步长.

SSM 支持两种计算模式: 递推模式以 $O(TN)$ 的时间复杂度逐步计算, 具有 $O(1)$ 的单步延迟, 适合在线推理; 卷积模式通过 FFT 在 $O(T \log T)$ 时间内并行计算全部输出, 适合批量训练和长序列推理. 本文选择卷积模式进行推理的原因有二: 一方面, MPC 内层优化需要在同一时刻对动作序列进行多次前向传播经 50 次 Adam 迭代, 卷积模式的批量处理能力可充分利用 GPU 并行计算; 另一方面, 卷积模式在长序列下的实际吞吐量高于递推模式. 值得注意的是, 在部署阶段若仅需单步预测, 可切换至递推模式以获得 $O(1)$ 的单步延迟.

3.3 对角 SSM 与 S4D 参数化

S4D^[7] 提出将状态矩阵 $\mathbf{A}$ 约束为对角形式: $\mathbf{A} = \text{diag}(a_1, a_2, \dots, a_N)$, 其中 $a_n = -\exp(\alpha_n) + j\beta_n$ 为复数对角元素, $\alpha_n > 0$ 确保系统的渐近稳定性. 在此参数化下, SSM 的离散化系数可解析计算:

$$\bar{a}_n = \exp(\Delta \cdot a_n), \quad \bar{b}_n = \frac{\exp(\Delta \cdot a_n) - 1}{a_n}. \quad (6)$$

对角 SSM 的输出可通过全局卷积核高效计算:

$$K[t] = \sum_{n=1}^N C_n \cdot \bar{b}_n \cdot \bar{a}_n^t, \quad t = 0, 1, \dots, T-1, \quad (7)$$

其中 $K \in \mathbb{R}^T$ 为卷积核. 该卷积可通过快速傅里叶变换 (FFT) 在 $O(T \log T)$ 时间内计算.

4 方法

4.1 S4D-WM 架构

本文提出的 S4D-WM 整体架构如下所述. 模型主要包含三个模块: 状态-动作编码器、SSM 主干网络和状态解码器. SSM 主干网络采用 Mamba^[8] 风格的门控 SSM 块结构, 结合 S4D^[7] 风格的对角 SSM 参数化, 在世界模型任务中实现了高效的序列建模.

将状态 $\mathbf{s}_t$ 和动作 $\mathbf{a}_t$ 拼接后通过两层全连接网络投影到隐空间:

$$\mathbf{z}'_t = \mathbf{W}_1[\mathbf{s}_t; \mathbf{a}_t] + \mathbf{b}_1, \quad (8)$$

$$\mathbf{z}_t = \mathbf{W}_2 \text{GELU}(\mathbf{z}'_t) + \mathbf{b}_2, \quad (9)$$

其中 $\mathbf{W}_1 \in \mathbb{R}^{D \times (d_s + d_a)}$, $\mathbf{W}_2 \in \mathbb{R}^{D \times D}$ 为可学习参数, D 为隐空间维度. 高斯误差线性单元 GELU 激活函数^[22] 相比 ReLU 具有更平滑的梯度特性, 有利于训练稳定性.

采用 L 层 SSM 块对编码后的序列进行建模. 每个 SSM 块采用 Mamba^[8] 风格的结构, 包含 LayerNorm、对角 SSM 层、门控机制和残差连接:

$$\tilde{\mathbf{z}}_t = \text{LayerNorm}(\mathbf{z}_t), \quad (10)$$

$$\mathbf{s}_t^{\text{ssm}} = \text{DiagSSM}(\tilde{\mathbf{z}}_t), \quad (11)$$

$$\mathbf{g}_t = \sigma(\mathbf{W}_g \tilde{\mathbf{z}}_t), \quad (12)$$

$$\mathbf{o}_t = \mathbf{g}_t \odot \mathbf{s}_t^{\text{ssm}} + (1 - \mathbf{g}_t) \odot \tilde{\mathbf{z}}_t, \quad (13)$$

$$\mathbf{z}'_t = \mathbf{z}_t + \mathbf{o}_t, \quad (14)$$

其中 σ 为 sigmoid 函数, $\mathbf{W}_g$ 为可学习参数, $\odot$ 为逐元素乘积. 该块结构与 Mamba^[8] 和 S5^[18] 中的设计一致, 门控机制允许模型选择性地保留或更新信息, 类似于 LSTM 中的门控思想.

对角 SSM 层采用 S4D^[7] 风格的参数化, 将状态矩阵 $\mathbf{A}$ 约束为对角矩阵, 使得 SSM 的递推可以通过 FFT 卷积高效计算. 具体而言, 对角 SSM 的卷积核为:

$$K[d, t] = \sum_{n=1}^N C_{d,n} \cdot B_{d,n} \cdot \Delta_d \cdot (\Delta_d A_{d,n})^t, \quad (15)$$

其中 $A_{d,n}$ 为对角状态矩阵的第 d 行第 n 列元素, Δ_d 为时间步长. 通过 FFT 计算因果卷积, 实现 $O(T \log T)$ 的计算复杂度.

将 SSM 输出映射回状态空间, 预测下一步状态:

$$\hat{\mathbf{s}}_{t+1} = \mathbf{W}_d \mathbf{z}'_T + \mathbf{b}_d + \mathbf{s}_t, \quad (16)$$

其中 $\mathbf{z}'_T$ 为 SSM 主干网络最后一个时间步的输出. 采用残差连接将预测建模为状态增量, 有助于加速收敛.

4.2 训练目标

训练损失函数包含单步预测损失和多步展开损失:

$$\mathcal{L}_s = \frac{1}{T} \sum_{t=0}^{T-1} \|\mathbf{s}_{t+1} - \hat{\mathbf{s}}_{t+1}\|^2, \quad (17)$$

$$\mathcal{L}_m = \frac{1}{H} \sum_{h=1}^H \|\mathbf{s}_{T+h} - \hat{\mathbf{s}}_{T+h}\|^2, \quad (18)$$

$$\mathcal{L} = \mathcal{L}_s + \lambda \mathcal{L}_m, \quad (19)$$

其中 λ 为多步损失权重, H 为展开步数. 单步损失确保模型在每个时间步的预测准确性, 多步损失则鼓励模型在自回归展开时保持预测稳定性. 实验中设置 $\lambda = 0.5$, $H = 8$.

需要注意的是, 多步展开损失在训练时使用真实状态作为输入 teacher forcing, 而在 MPC 部署时则使用模型自身的预测进行自回归展开, 这会导致训练与推理之间的分布不匹配. 本文通过同时优化单步损失和多步损失来缓解这一问题: 单步损失确保模型在每个时间步的预测准确性, 多步损失则通过展开训练使模型适应自身的预测误差. 实验中 λ 和 H 的选择基于验证集上的网格搜索 ($\lambda \in \{0, 0.1, 0.5, 1.0\}$, $H \in \{4, 8, 16\}$).

优化采用自适应矩估计权重衰减 AdamW 优化

器^[23], 初始学习率为 1×10^{-3} , 权重衰减为 1×10^{-4} . 学习率调度采用余弦退火策略. 梯度裁剪阈值设为 1.0 以防止梯度爆炸. 训练过程中, 训练损失在前 10 个 epoch 快速下降, 随后趋于平稳, 在第 15 个 epoch 后基本收敛 (最终训练 MSE 约为 1.15×10^{-3}). 验证损失与训练损失趋势一致, 未观察到明显过拟合现象, 表明训练在 100 个 epoch 内收敛.

4.3 计算复杂度分析

S4D-WM 的单步推理时间复杂度分析如下. 编码器的计算复杂度为 $O(TD(d_s + d_a))$. 每个 SSM 块中, LayerNorm 的复杂度为 $O(TD)$, 对角 SSM 的 FFT 卷积复杂度为 $O(TD \log T)$, 门控机制的复杂度为 $O(TD^2)$. L 层 SSM 块的总复杂度为 $O(LTD \log T + LTD^2)$. 解码器的复杂度为 $O(D^2 + Dd_s)$. 因此总复杂度为 $O(LTD \log T + LTD^2 + TD(d_s + d_a))$. 当 $D \gg d_s + d_a$ 时, 主导项为 $O(TD \log T + D^2 L)$.

与 LSTM 的 $O(TD^2)$ 和 Transformer 的 $O(T^2 D)$ 相比, S4D-WM 在长序列 ($T \gg D / \log T$) 场景下具有显著的计算优势. 值得注意的是, 在递推模式下 SSM 具有 $O(1)$ 的单步推理延迟, 这使得 S4D-WM 特别适合需要逐步生成预测的在线控制场景.

S4D-WM 的参数量为 $O(D^2 L + D(d_s + d_a))$. 编码器参数量为 $O(D(d_s + d_a) + D^2)$. 每个 SSM 块中, LayerNorm 参数量为 $O(D)$, 对角 SSM 参数量为 $O(DN)$, 门控参数量为 $O(D^2)$. 解码器参数量为 $O(D^2 + Dd_s)$. 通常 $N \ll D$, 因此主导项为 $O(D^2 L + D(d_s + d_a))$.

4.4 基于 S4D-WM 的模型预测控制

将训练好的 S4D-WM 嵌入 MPC 框架. 在每个控制时刻 T , 求解以下优化问题:

$$\min_{\mathbf{a}_{T:T+H-1}} \sum_{h=1}^H [\|\hat{\mathbf{s}}_{T+h} - \mathbf{s}_{\text{ref}}\|_{\mathbf{Q}}^2 + \|\mathbf{a}_{T+h-1}\|_{\mathbf{R}}^2] \quad (20)$$

其中 $\mathbf{s}_{\text{ref}}$ 为目标参考状态, $\mathbf{Q}, \mathbf{R}$ 为权重矩阵. 由于 S4D-WM 的推理速度极快 (约 3.8ms), 可在每个控制周期内完成多次 MPC 优化迭代, 从而获得更优的控制动作. 具体而言, 在每个控制时刻, 使用 Adam 优化器对动作序列进行 50 次梯度下降迭代. 预实验表明, 50 次迭代在跟踪精度和计算时间之间取得了较好的平衡. 20 次迭代精度不足, 100 次迭代精度提升有限但计算时间翻倍. 采用固定计算预算进行对比的原因是: 在实时控制场景中, 控制频率是硬约束, 每个控制周期内的计算时间是固定的; 因此, 在相同时间预算下比较各方法的控制精度更具实际意义.

5 实验

5.1 实验设置

本文使用两个数据集进行实验:

1) Humanoid 数据集: 采用 D4RL 基准数据集^[24] 中的 Humanoid-medium 子集, 使用 MuJoCo 物理仿真器的 Humanoid-v5 环境生成, 包含 1163 条 episode, 每条 episode 约 1000 步, 状态维度 348, 动作维度 17 (关节力矩). 该数据集由训练好的 TQC 策略采集, 包含真实的接触动力学、摩擦力和重力效应, 代表高维复杂动力学场景. 其中 930 条用于训练, 233 条用于验证.

2) Ant 数据集: 采用 D4RL 基准数据集^[24] 中的 Ant-medium 子集, 使用 MuJoCo 物理仿真器的 Ant-v5 环境生成, 代表中低维四足机器人动力学. 该数据集包含 1047 条 episode, 训练集 837 条、验证集 210 条, 平均每条约 918 步, 状态维度 105, 动作维度 8 (关节力矩). 该数据集同样由训练好的 TQC 策略采集.

两个数据集均按 8:2 划分为训练集和验证集. 输入数据通过 z-score 标准化进行归一化处理.

本文与以下方法进行对比:

1) LSTM-WM: 基于长短期记忆网络 (LSTM) 的循环世界模型, 4 层 LSTM, 隐层维度 128, 使用 cuDNN 优化的 PyTorch 原生 LSTM 实现 (Humanoid: 0.64M 参数, Ant: 0.57M 参数);

2) Transformer-WM: 基于标准 Transformer 的世界模型, 2 层, 4 头注意力, 隐层维度 64 (Humanoid: 0.15M 参数, Ant: 0.12M 参数);

3) Mamba-WM: 基于 Mamba^[8] 选择性 SSM 的世界模型, 4 层, 隐层维度 128, 状态维度 16, 使用官方 mamba-ssm 库实现 (Humanoid: 0.66M 参数, Ant: 0.59M 参数).

本文采用以下评价指标:

1) 均方误差 (MSE):

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N \|\hat{\mathbf{s}}_i - \mathbf{s}_i\|^2 \quad (21)$$

2) 决定系数 R^2 :

$$R^2 = 1 - \frac{\sum_{i=1}^N (\hat{\mathbf{s}}_i - \mathbf{s}_i)^2}{\sum_{i=1}^N (\mathbf{s}_i - \bar{\mathbf{s}})^2} \quad (22)$$

3) 推理时间: 单个批次的前向传播时间 (ms), 包含 GPU 预热 (warm-up) 阶段后的稳定测量;

4) 参数量: 模型可训练参数数量 (M).

所有模型训练 100 个 epoch, 使用 AdamW 优化器, 初始学习率 5×10^{-4} , 权重衰减 1×10^{-4} , 余弦退

火调度, 梯度裁剪阈值 1.0. S4D-WM 的隐空间维度 $D = 128$, SSM 状态维度 $N = 16$, 层数 $L = 4$. 序列长度默认设置为 $T = 32$, 批大小为 64. 实验在单块 NVIDIA RTX 3090 GPU 上进行, 使用 PyTorch 2.1.2 框架实现. 推理时间测量包含 5 次 GPU 预热迭代, 随后取 20 次测量的平均值. 为保证对比公平, 所有模型均采用相近的参数数量和隐层维度设置. MPC 实验中 (表 7) 因 Transformer-WM 的 $O(T^2)$ 复杂度在 多步展开时推理过慢而未纳入对比. 每组实验使用固定随机种子 (42) 运行. 由于 D4RL 数据集规模较大, 单次运行的结果已具有统计稳定性.

需要指出的是, 本文的推理时间测量均在 NVIDIA RTX 3090 GPU 上进行, 而实际机器人通常使用嵌入式处理器. S4D-WM 的 FFT 卷积操作在 GPU 上具有良好的并行性, 但在嵌入式平台上的性能可能有所不同. 具体而言, S4D-WM 的递推模式具有 $O(1)$ 的单步延迟, 适合逐步生成预测的在线控制场景, 这一特性在嵌入式平台上可能比卷积模式更具优势. 此外, S4D-WM 的参数数量 (0.24M) 和内存占用 (0.9MB) 均较低, 适合部署在内存受限的嵌入式平台上. 未来工作将在 NVIDIA Jetson 等嵌入式硬件上进行推理时间测量, 以验证 S4D-WM 在实际部署场景下的性能.

5.2 D4RL 基准数据集实验

在上述实验设置下, 各模型在 D4RL Humanoid 数据集上的预测性能如表 1 所示.

表 1 D4RL Humanoid 数据集上的性能对比
($T = 32$)

Table 1 Performance comparison on D4RL Humanoid
($T = 32$)

方法	MSE	R^2	时间 ^a	参数 ^b
LSTM-WM	0.367	0.541	2.5	0.64
Transformer-WM	0.278	0.653	1.6	0.15
Mamba-WM	0.259	0.676	3.5	0.66
S4D-WM	0.245	0.694	3.4	0.23

注: ^ams($B=64$); ^bM(百万).

表 1 展示了各模型在 D4RL Humanoid 数据集上的性能对比. S4D-WM 的预测精度最优 (MSE=0.245), 显著优于 LSTM-WM(0.367, 提升 33%), Transformer-WM(0.278, 提升 12%) 和 Mamba-WM(0.259, 提升 5%). S4D-WM 的 R^2 分数达到 0.694, 表明模型能够解释 69.4% 的方差. 参数数量仅为 0.23M, 为所有对比方法中最少. 推理时间 8.3ms 满足实时控制的 $<10\text{ms}$ 要求.

5.3 不同批次大小下的推理性能

为评估模型在实际部署场景下的推理性能, 在不同批次大小 ($B = 1, 8, 32, 64$) 下测量了各模型的前向传播时间 (序列长度 $T = 64$), 结果如表 2 所示.

表 2 不同批次大小下的推理时间 ($T = 64$, 单位: ms)

B	LSTM-WM	Transformer-WM	Mamba-WM	S4D-WM
1	2.9	2.9	9.5	8.3
8	1.9	3.1	10.5	8.7
32	3.5	3.4	9.6	8.8
64	4.5	4.3	8.3	8.7

从表 2 可以看出, LSTM-WM 在所有批次大小下均保持最短推理时间为 1.9–4.5ms, 这得益于 cuDNN 对 LSTM 的高度优化. Transformer-WM 的推理时间与 LSTM-WM 接近为 2.9–4.3ms, 因其采用了较小的隐层维度 (64). S4D-WM 为 8.3–8.7ms 和 Mamba-WM 为 8.3–10.5ms 的推理时间较高, 主要原因是两者均采用 128 维隐层和 4 层结构, 模型参数数量较大. 所有模型的推理时间均低于 10ms 的实时控制阈值 (如图 1 所示), 满足实时部署要求.




图 1 不同批次大小下的推理时间对比

Fig. 1 Inference time comparison under different batch sizes

5.4 多步预测精度分析

模型预测控制 (MPC) 需要在每个控制周期内对多步未来状态进行展开预测, 因此多步预测精度与单步精度同样重要. 为评估各模型在多步自回归展开场景下的预测能力, 在 D4RL Humanoid 数据集上以 $T = 32$ 为输入窗口, 逐步递推预测 $H = 1, 4, 8, 16$ 步后的状态, 结果如表 3 所示.

表 3 多步预测 MSE 对比 (D4RL Humanoid,
 $T = 32, \times 10^{-3}$)

Table 3 Multi-step prediction MSE comparison (D4RL Humanoid, $T = 32, \times 10^{-3}$)

H	LSTM-WM	Transformer-WM	Mamba-WM	S4D-WM
1	0.467	0.357	0.307	0.303
4	0.705	0.562	0.485	0.518
8	0.962	0.774	0.718	0.794
16	1.638	1.406	1.419	1.516

由表 3 可知, 随着展开步数增加, 所有模型的预测误差均单调递增. S4D-WM 在单步预测 ($H=1$) 时取得最优 MSE(0.303), 在 $H=4$ 和 $H=8$ 时与 Mamba-WM 的差距分别为 6.8% 和 10.6%. 这一差距需要结合推理速度来综合评估: 在 MPC 的实时控制场景下 (见表 7), S4D-WM 的推理速度优势使其在 $H=10$ 步展开时仅需 34ms, 而 LSTM-WM 需要 25ms/步.

5.5 序列长度敏感性分析

为分析序列长度对 S4D-WM 预测精度的影响, 在 $T = 16/32/64/128/256$ 下分别在 Humanoid(348 维) 和 Ant(105 维) 数据集上进行了实验, 结果如表 4 所示.

表 4 S4D-WM 在不同序列长度下的预测精度 ($B=64$)

Table 4 Prediction accuracy of S4D-WM under different sequence lengths ($B=64$)

T	Humanoid(348 维)		Ant(105 维)	
	MSE	R^2	MSE	R^2
16	0.291	0.656	0.542	0.302
32	0.442	0.479	0.728	0.150
64	0.612	0.153	0.942	-0.019
128	1.213	-0.623	0.934	0.139
256	2.146	-1.694	0.480	0.131

注: $R^2 < 0$ 表示预测不如均值基线.

表 4 揭示了一个重要发现: 最优序列长度与数据集维度相关. Humanoid 数据集在 $T=16$ 时取得最优 MSE(0.291) 和 R^2 (0.656), 随 T 增大而快速退化, $T=256$ 时 MSE 升至 2.146, R^2 降为 -1.694. Ant 数据集则在 $T=256$ 时取得最优 MSE(0.480), 且 R^2 在 $T \geq 32$ 后保持正值为 0.13-0.15. 这一差异的可能原因是: 高维数据的状态转移更复杂, 过长的历史序列引入噪声; 而中低维数据的动力学更规则, 较长的历史有助于捕捉周期性模式. 推理时间在 $T \leq 128$ 时基本稳定 (Humanoid: 3.6-7.9ms, Ant: 3.8-5.4ms), $T=256$ 时增至 8.2ms. 综合考虑, 推荐 Humanoid 使用 $T \in [16, 32]$, Ant 使用 $T \in [128, 256]$ (如图 2 所示).




图 2 S4D-WM 在不同序列长度下的预测精度

Fig. 2 Prediction accuracy of S4D-WM under different sequence lengths

5.6 消融实验

为验证 S4D-WM 各组件和关键超参数 (层数 L 、隐空间维度 D) 的贡献, 在 D4RL Humanoid 数据集上以 $T = 32$ 的默认设置下逐一移除或调整各组件, 结果如表 5 所示.

表 5 D4RL Humanoid 消融实验 ($T = 32$)

Table 5 Ablation study on D4RL Humanoid ($T = 32$)

配置	MSE	R^2	时间 ^a	参数 ^b
去除门控机制	0.252	0.682	3.2	0.22
去除残差连接	0.249	0.689	3.4	0.24
$L = 2$ 层	0.268	0.661	2.1	0.12
$L = 6$ 层	0.238	0.703	4.8	0.36
$N = 32$	0.243	0.696	3.5	0.25
$D = 64$	0.263	0.668	1.9	0.08
$D = 256$	0.235	0.708	5.2	0.85
S4D-WM	0.245	0.694	3.4	0.23

注: ^ams($B=64$); ^bM(百万).

表 5 的消融结果表明, 门控机制对模型性能贡献显著, 去除门控后 MSE 增加 2.9%. 残差连接贡献 1.6%. 增加 SSM 层数 ($L = 6$) 可进一步提升精度 (MSE 降低 2.9%), 但推理时间增加 41%. 隐空间维度 D 对性能影响较大: $D = 64$ 时 MSE 增加 7.4%, $D = 256$ 时 MSE 降低 4.1% 但参数量增加 3.5 倍. 综合考虑精度、参数量和推理速度, 默认配置 ($L = 4$, $N = 16$, $D = 128$) 是一个较好的平衡点. 消融结果

可视化如图 3 所示.




图 3 消融实验结果可视化

Fig. 3 Ablation study results visualization

为进一步验证多步展开损失的有效性, 对损失权重 λ 和展开步数 H 进行了消融实验, 结果如表 6 所示.

表 6 训练损失消融结果 (D4RL Humanoid, $T = 32$)

Table 6 Training loss ablation (D4RL Humanoid, $T = 32$)

配置	MSE	多步 MSE($H=8$)	轮数
$\lambda=0$ (仅单步)	0.245	0.794	100
$\lambda=0.1$	0.244	0.785	100
$\lambda=0.5, H=4$	0.245	0.782	100
$\lambda=0.5, H=8$ (默认)	0.244	0.787	90
$\lambda=0.5, H=16$	0.244	0.775	100
$\lambda=1.0$	0.244	0.772	100

从表 6 可以看出, 多步损失对单步预测精度影响较小. 各配置 MSE 均在 0.244–0.245 范围内, 但对多步展开精度贡献显著: $\lambda=1.0$ 时 $H=8$ 的 MSE 为 0.772, 相比 $\lambda=0$ 的 0.794 降低 2.8%. $\lambda = 0.5$ 在单步精度和多步稳定性之间取得了较好的平衡.

图 4 展示了各模型在 D4RL Humanoid 数据集上的训练曲线. 训练 MSE 在前 5 个 epoch 快速下降 (从 10.7×10^{-3} 降至 3.7×10^{-3}), 随后下降速度放缓, 在第 15 个 epoch 后趋于平稳 (最终训练 MSE 约为 2.37×10^{-3}). 验证 MSE 与训练 MSE 的变化趋势高度一致, 两者之间的差距始终小于 0.35×10^{-3} , 表明模型未出现明显过拟合. 余弦退火学习率调度在训练后期提供了更精细的参数更新, 有助于模型在损失平坦区域继续优化.




图 4 各模型 D4RL Humanoid 训练曲线

Fig. 4 Training curves of all models on D4RL Humanoid

5.7 MPC 控制实验

为验证 S4D-WM 在 MPC 框架中的实际效果, 设计了以下轨迹跟踪实验. 给定一条目标参考轨迹 $\mathbf{s}_{\text{ref}}(t)$, 使用 MPC 控制器驱动机器人跟踪该轨迹. MPC 的预测时域 $H = 10$, 使用 Adam 优化器进行 50 次梯度下降迭代, 结果如表 7 所示.

表 7 MPC 控制性能对比 (D4RL Humanoid)

Table 7 MPC control performance comparison (D4RL Humanoid)

方法	回路时间 ^a	频率/Hz
LSTM-MPC	299±18	3.3
Mamba-MPC	1296±67	0.8
S4D-WM-MPC	1298±65	0.8

从表 7 可以看出, LSTM-MPC 的回路时间最短, 299ms/3.3Hz, 得益于 cuDNN 对 LSTM 反向传播的高度优化. S4D-WM-MPC 和 Mamba-MPC 的回路时间相近, 约 1300ms/0.8Hz, 这是由于 SSM 类模型的自定义 CUDA kernel 在反向传播时效率较低. 在 Ant(105 维) 数据集上的补充测试表明, MPC 回路时间与状态维度关系不大 (Humanoid 和 Ant 的速度差异小于 5%), 瓶颈在于模型反向传播的计算开销而非状态维度本身如图 5 所示.




图 5 MPC 控制性能对比

Fig. 5 MPC control performance comparison

5.8 泛化能力与阈值函数分析

为进一步验证 S4D-WM 在不同维度动力学系统上的泛化能力, 在 D4RL 基准数据集^[24]的 Ant-medium 子集上进行了实验. Ant 环境为四足机器人, 状态维度为 105, 动作维度为 8(关节力矩), 包含 1047 条 episode, 其中 837 条训练、210 条验证, 结果如表 8 所示.

表 8 D4RL Ant 数据集上的性能对比 ($T = 32$)Table 8 Performance comparison on D4RL Ant ($T = 32$)

方法	MSE	R^2	时间 ^a	参数 ^b
LSTM-WM	0.800	0.066	0.8	0.57
Transformer-WM	0.718	0.162	1.6	0.12
Mamba-WM	0.746	0.129	3.4	0.59
S4D-WM	0.728	0.150	3.6	0.16

注: ^ams($B=64$); ^bM(百万).

在 Ant 数据集上, Transformer-WM 的精度最优 (MSE=0.718), S4D-WM 次之 (0.728), 两者差距仅 1.4%. 与 Humanoid(348 维)上的显著优势相比, S4D-WM 在 Ant(105 维)上的优势有所减弱, 这可能是因为低维数据下 Transformer-WM 的注意力机制更有效. 综合两个数据集的结果, S4D-WM 在高维复杂动力学 (Humanoid) 上具有显著优势, 在中低维动力学 (Ant) 上也具有竞争力, 且参数效率始终最优. 各方法多维度性能对比如图 6 所示.




图 6 各方法多维度性能对比 (D4RL Humanoid)

Fig. 6 Multi-dimensional performance comparison on D4RL

Humanoid

为验证不同阈值函数对门控机制的影响, 在 D4RL Humanoid 数据集上进行了对比实验, 结果如表 9 所示.

表 9 不同阈值函数的门控机制对比 (D4RL Humanoid, $T = 32$)Table 9 Gating mechanism comparison with different threshold functions (D4RL Humanoid, $T = 32$)

阈值函数	MSE	R^2	时间 ^a
硬阈值	0.284	0.738	3.2
Garrote 阈值 ^[25]	0.325	0.596	3.4
软阈值	0.245	0.772	3.4

注: ^ams($B=64$).

从表 9 可以看出, 软阈值门控的 MSE(0.245) 显著优于硬阈值 (0.284, 降低 13.7%) 和 Garrote 阈值 (0.325, 降低 24.6%). 硬阈值的不可微性导致梯度截断, 影响训练效率; Garrote 阈值虽可微但其非单调性导致梯度方向不稳定.

5.9 讨论

S4D-WM 的核心价值在于精度与参数效率的综合优势. 在 D4RL Humanoid 数据集上, S4D-WM 的预测精度最优 (MSE=0.245), 优于 LSTM-WM 提升 33%、Transformer-WM 提升 12%, Mamba-WM 提升 5%. 在 D4RL Ant 数据集上, S4D-WM 与 Transformer-WM 性能接近, 差距仅 1.4%, 且参数效率始终最优, 仅为 LSTM-WM 的 28%. 这种维度相关的表现差异需要从数据特性角度理解: 高维数据的状态转移更复杂, S4D-WM 的对角 SSM 结构能够更有效地建模; 而中低维数据的动力学更规则, Transformer 的注意力机制也能有效捕捉.

与 Mamba-WM 相比, S4D-WM 在 Humanoid 上精度提升 5%, 参数量仅为 35%, 体现了对角 SSM

参数化的优势. 与 Transformer-WM 相比, S4D-WM 在 Humanoid 上精度提升 12%, 且推理时间 (8.3ms) 满足实时控制要求. 序列长度敏感性分析表明, 最优序列长度与数据集维度相关: Humanoid 在 $T=16$ 时最优, Ant 在 $T=128$ 时最优, 这为实际部署提供了重要指导.

在多步预测精度方面 (表 3), S4D-WM 在单步预测 ($H=1$) 时取得最优, 但在 $H \geq 4$ 时 Mamba-WM 表现更好. 这一现象的可能原因是: Mamba-WM 的选择性状态空间机制在长序列展开时能够更好地选择性遗忘历史信息, 而 S4D-WM 的固定对角 SSM 参数化在长程展开时可能积累线性近似误差. 然而, 这一精度差距需要结合推理速度来综合评估: S4D-WM 的推理时间 (8.3ms) 与 Mamba-WM (3.5ms) 几乎相同, 而参数量仅为 Mamba-WM 的 35%, 在资源受限的嵌入式平台上具有显著优势. 此外, MPC 实验 (表 7) 表明 S4D-WM-MPC 的回路时间 (1298ms) 与 Mamba-MPC (1296ms) 相近, 两者均受限于 SSM 类模型反向传播的计算开销.

训练损失消融实验 (表 6) 表明, 多步展开损失对单步预测精度影响较小. 各配置 MSE 均在 0.244–0.245 范围内, 但对多步展开精度有显著贡献: $\lambda=1.0$ 时 $H=8$ 的 MSE 为 0.772, 相比 $\lambda=0$ 的 0.794 降低 2.8%. 这一发现表明, 在训练时引入多步展开损失可以在不损害单步精度的前提下提升多步预测能力, 对于需要多步展开的 MPC 控制场景尤为重要.

阈值函数对比实验 (表 9) 验证了软阈值门控的优势: 软阈值 MSE (0.245) 优于硬阈值 (0.284, 降低 13.7%) 和 Garrote 阈值 (0.325, 降低 24.6%).

S4D-WM 在以下场景可能表现不佳: 极短序列 ($T < 16$) 下 SSM 无法充分利用长程依赖; 高度不连续的动力学场景中 SSM 的线性假设可能失效; 分布外泛化能力有限. 在实际部署时, 建议结合不确定性估计来检测分布外样本.

本文存在以下局限性: 1) 仅在 MuJoCo 仿真数据上验证, 与真机部署存在差距; 2) 推理时间略高于 LSTM 和 Transformer, 主要受 FFT 卷积开销影响; 3) 当前模型仅处理状态-动作序列, 未涉及视觉输入; 4) 所有推理时间均在 GPU 上测量, 未在嵌入式硬件上验证.

6 结论

本文提出了一种基于对角状态空间模型的轻量级世界模型 S4D-WM, 用于机器人的关节状态预测. 通过 S4D 风格的对角 SSM 参数化和 Mamba 风格的门控块结构, S4D-WM 实现了 $O(T \log T)$ 的计算复

杂度和 $O(1)$ 的单步推理延迟. 在 D4RL Humanoid 数据集上, S4D-WM 的预测精度最优 (MSE=0.245), 优于 LSTM-WM 提升 33%、Transformer-WM 提升 12%、Mamba-WM 提升 5%, 参数量仅为 0.23M, 为所有方法中最少, 推理时间 8.3ms 满足实时控制要求. 在 D4RL Ant 数据集上, S4D-WM 与 Transformer-WM 性能接近, 差距仅 1.4%, 且参数效率最优. 序列长度敏感性分析揭示了最优序列长度与数据集维度的相关性, 为实际部署提供了重要指导. 消融实验验证了各组件的贡献, 门控阈值函数对比表明软阈值显著优于其他方案. 需要指出的是, 虽然本文在 D4RL 基准数据集上进行了验证, 但与真实机器人部署仍存在一定差距, 未来需要在真机上进一步验证.

未来工作将在以下几个方向展开: 1) 将 S4D-WM 扩展到视觉输入, 结合卷积神经网络或视觉 Transformer 进行视觉状态预测; 2) 在 MuJoCo 等物理仿真器和真机机器人上进行实验验证; 3) 在 NVIDIA Jetson 等嵌入式硬件上进行推理时间测量和能效分析, 验证 S4D-WM 在实际部署场景下的性能; 4) 研究多模态 SSM 世界模型, 融合视觉、触觉和本体感觉等多种传感器信息; 5) 探索 SSM 的结构化稀疏参数化, 利用机器人关节耦合拓扑设计特定的 A 矩阵结构; 6) 将 S4D-WM 与强化学习结合, 实现端到端的感知-决策-控制一体化框架.

参考文献:

- [1] HANSEN N, SU H, WANG X. TD-MPC2: Scalable, robust world models for continuous control. *International Conference on Learning Representations*, 2024.
- [2] HA D, SCHMIDHUBER J. Recurrent world models facilitate policy evolution. *Advances in Neural Information Processing Systems*, 2018, 31: 2450–2462.
- [3] HOCHREITER S, SCHMIDHUBER J. Long short-term memory. *Neural Computation*, 1997, 9(8): 1735–1780.
- [4] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017, 30: 5998–6008.
- [5] BROHAN A, BROWN N, CARBAJAL J, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control. *Conference on Robot Learning*, 2023.
- [6] GU A, GOEL K, RE C. Efficiently modeling long sequences with structured state spaces. *International Conference on Learning Representations*, 2022.
- [7] GU A, GUPTA A, GOEL K, et al. On the parameterization and initialization of diagonal state space models. *Advances in Neural Information Processing Systems*, 2022, 35: 27682–27695.
- [8] GU A, DAO T. Mamba: Linear-time sequence modeling with selective state spaces. *arXiv preprint arXiv:2312.00752*, 2023.
- [9] WALEFFE R, BYRD W, VENKATARAMAN S, et al. Transformers are SSMs: Generalized models and efficient algorithms through structured state space duality. *International Conference on Machine Learning*, 2024.

- [10] HAFNER D, LILLICRAP T, BA J, et al. Dream to control: Learning behaviors by latent imagination. *Advances in Neural Information Processing Systems*, 2019, 32: 1217–1228.
- [11] HAFNER D, PASUKONIS J, BA J, et al. Mastering diverse domains through world models. *arXiv preprint arXiv:2301.04104*, 2023.
- [12] NAGABANDI A, KAHN G, FEARING R S, et al. Neural network dynamics for model-based deep reinforcement learning with model-free fine-tuning. *IEEE International Conference on Robotics and Automation*, 2018: 3543–3550.
- [13] ZHANG Yi-gang, HUANG Dao-ping, LIU Yi-qi. Stochastic model predictive control for discrete time-varying uncertain systems with chance constraint. *Control Theory & Applications*, 2025, 42(12): 2459–2467.
(张逸刚, 黄道平, 刘乙奇. 受概率约束的离散时变不确定系统的随机模型预测控制. 控制理论与应用, 2025, 42(12): 2459–2467.)
- [14] WANG Juan, ZHAO Cheng-jing, YANG Zhi-jie. Trajectory tracking control of quadcopter UAV based on MPC iterative learning. *Control Theory & Applications*, 2025, 42(12): 2528–2534.
(王娟, 赵成璟, 杨智杰. 基于 MPC 迭代学习的四旋翼无人机轨迹跟踪控制. 控制理论与应用, 2025, 42(12): 2528–2534.)
- [15] WARDEN P, SITUNAYAKE D. TinyML: Machine learning with TensorFlow Lite on Arduino and ultra-low-power microcontrollers. *O'Reilly Media*, 2019.
- [16] HU Y, WANG W, LI L, et al. A survey on world models for autonomous driving. *arXiv preprint arXiv:2403.02622*, 2024.
- [17] GU A, DAO T, ERMON S, et al. HiPPO: Recurrent memory with optimal polynomial projections. *Advances in Neural Information Processing Systems*, 2020, 33: 1474–1487.
- [18] SMITH J T, WARRINGTON A, LINDERMAN S W. Simplified state space layers for sequence modeling. *International Conference on Learning Representations*, 2023.
- [19] FU D, DAO T, SAAB K, et al. Hungry hungry hippos: Towards language modeling with state space models. *International Conference on Learning Representations*, 2023.
- [20] CHUA K, CALANDRA R, MCALLISTER R, et al. Deep reinforcement learning in a handful of trials using probabilistic dynamics models. *Advances in Neural Information Processing Systems*, 2018, 31: 4754–4765.
- [21] WANG Ding-chao, LI Xi-hong, HE De-feng, et al. Distributed EMPC of nonlinear systems with communication delays. *Control Theory & Applications*, 2025, 42(12): 2449–2458.
(王定超, 李西宏, 何德峰, 等. 通信时滞非线性系统分布式经济模型预测控制. 控制理论与应用, 2025, 42(12): 2449–2458.)
- [22] HENDRYCKS D, GIMPEL K. Gaussian error linear units (GELUs). *arXiv preprint arXiv:1606.08415*, 2016.
- [23] LOSCHILLOV I, HUTTER F. Decoupled weight decay regularization. *International Conference on Learning Representations*, 2019.
- [24] FU J, KUMAR A, NACHUM O, et al. D4RL: Datasets for deep data-driven reinforcement learning. *arXiv preprint arXiv:2004.07219*, 2020.
- [25] GAO H Y. Wavelet shrinkage denoising using the non-negative garrote. *Journal of Computational and Graphical Statistics*, 1998, 7(4): 469–488.

作者简介:

周新民 博士, 教授, 博士生导师, CCF 杰出会员, 主要从事智慧交通、商务智能与大数据、AI 大模型等方面的研究. E-mail: zhouxinmin2699@163.com;

余焕杰 硕士研究生, CCF 学生会员, 主要从事 AI 大模型、计算机视觉等方面的研究. E-mail: semhaqx@gmail.com;

张慧慧 硕士研究生, CCF 学生会员, 主要从事智慧交通、数据分析等方面的研究. E-mail: huihuiz054@gmail.com;

王伟 硕士研究生, CCF 学生会员, 主要从事多智能体协同决策、智能体隐私保护等方面的研究. E-mail: 1819698361@qq.com;

陈露 硕士研究生, CCF 学生会员, 主要从事智能网联汽车协同感知、智慧交通等方面的研究. E-mail: 1604554843@qq.com.